

TRABAJO DE FIN DE MÁSTER

GeoAssets Intelligence

Localización automatizada del patrimonio productivo empresarial mediante IA generativa

AUTORE

Sergio Hervás Santiago
Alonso Salgueiro Castelo
Claudia García de Villegas

TUTOR

Segismundo Jiménez
Lainez

PROGRAM

Máster en Consultoría de
Negocio

Índice


01	Contexto y oportunidad
02	La solución
03	Arquitectura técnica
04	Pipelines de análisis
05	Demostración y resultados
06	Benchmarking
07	Propuesta de valor y cierre
08	Bibliografía y anexos

1

¿De qué trata este TFM? PUNTO DE PARTIDA

“Localizar todos los activos productivos de una empresa requiere **horas de trabajo manual** sin garantía de cobertura completa.”

PROCESO MANUAL ACTUAL



PROBLEMA



SOLUCIÓN



1

El problema

Contexto de mercado: activos productivos invisibles para los datos públicos

Llamamos **activo productivo** a cualquier instalación física desde la que una empresa genera valor: fábricas, oficinas, centros logísticos, puntos de venta, instalaciones energéticas o agrícolas. Su localización es un input crítico en múltiples sectores.

BANCA

Riesgo colateral

Valoración de garantías y exposición geográfica

CONSULTORÍA

&A y due diligence

Mapeo de patrimonio en operaciones

SEGUROS

Suscripción y siniestros

Concentración de riesgo por zona

ESG

Exposición ambiental

Activos industriales en zonas sensibles

ESPAÑA · ACTIVOS POR TIPO

HQ / FÁBRICA

LOGÍSTICA / OFICINA

OTRO

1

El analista hace 4 saltos antes de tener un solo activo geolocalizado

AS IS · El proceso manual actual

Las nuevas exigencias regulatorias impulsadas por Société Générale obligan a las compañías a incorporar el cálculo de riesgos físicos dentro de sus marcos de gestión de riesgo climático.

01 · BUSCAR

Web abierta + LinkedIn

Consultas dispersas en Google, prensa sectorial y notas de inversores.

⚠ **Resultado ruidoso**

02 · CONTRASTAR

Reg. Mercantil + informes

Cruce con CNAE, memorias anuales y filiales declaradas.

⚠ **Sin coordenadas**

03 · GEOCODIFICAR

Pegar dirección a mano

Conversión manual de dirección postal a lat/lon en mapas.

⚠ **Errores tipográficos**

04 · VALIDAR

¿Sigue operativo?

Verificar vigencia, categoría correcta y pertenencia real al grupo.

⚠ **Activos cerrados**

TIEMPO

2–4 horas / empresa

Para una cobertura parcial estimada del 40–60 % del patrimonio real.

CALIDAD

~30% errores frecuentes

Activos cerrados, categoría incorrecta, dirección sin coordenadas.

REPRODUCIBILIDAD

COBERTURA PARCIAL

ALTO RIESGO DE ERROR

1

Las herramientas actuales resuelven una pieza, nunca el conjunto

SOLUCIONES EXISTENTES


FUENTE / HERRAMIENTA	COBERTURA	GEOLOCALIZACIÓN	FILTRA ACTIVOS PRODUCTIVOS	SCORING DE CONFIANZA	AUTOMATIZACIÓN
Fuentes públicas CNAE, Reg. Mercantil	◀ Parcial	✗ Solo dirección	✗	✗	✗ Manual
Google Maps API Places + Geocoding	✓ Amplia	✓ Lat/Lon	✗ Mezcla todo tipo de POI	✗	◀ Bruta
Inteligencia competitiva Bureau van Dijk, Dun & B.	✓ Amplia	◀ Variable	◀ Manual	✗	✗ Cara · sin API
Scrapers ad-hoc Custom, por equipo	◀ Frágil	◀	◀ Reglas duras	✗	◀
GeoAssets Intelligence Esta propuesta	✓ Multi-fuente	✓ Lat/Lon + dirección	✓ LLM clasifica 12 cat.	✓ Score 0–100 + tiers	✓ End-to-end

CONCLUSIÓN · Ninguna fuente individual cubre simultáneamente **cobertura amplia**, **geolocalización fiable**, **filtrado por tipo de activo** y **scoring objetivo**. La oportunidad está en orquestarlas.

1

Tres tecnologías han madurado a la vez. Es el momento. OPORTUNIDAD

Por primera vez disponemos simultáneamente de modelos de lenguaje capaces de razonar sobre texto no estructurado, APIs geoespaciales con cobertura global, y frameworks de agentes que orquestan ambos sin intervención humana.



1

Un sistema end-to-end con mínima intervención humana

OBJETIVO Y ALCANCE

INPUT

Nombre de empresa

"Inditex"

O un documento PDF/Excel con activos. O simplemente un nombre y dejamos al agente buscar.

Sistema

GeoAssets Intelligence

PIPELINE 1

Maps API

PIPELINE 2

Documento

PIPELINE 3

Agente IA

Localiza · clasifica en 12 categorías · puntúa cada activo con un **score 0-100** y un tier de confianza.

OUTPUT

Mapa + dataset

HIGH ≥ 70

Validable directo

MEDIUM 40-69

Revisión rápida

LOW < 40

Descartable

Exportable a CSV / Excel con todos los campos y las señales del score.

KPIS DE ÉXITO DEFINIDOS

≥ 80%

COBERTURA DE ACTIVOS CONOCIDOS

≥ 60%

RESULTADOS EN TIER HIGH

12

CATEGORÍAS DE ACTIVO DEFINIDAS

Índice

01	Contexto y oportunidad
02	La solución
03	Arquitectura técnica
04	Pipelines de análisis
05	Demostración y resultados
06	Benchmarking
07	Propuesta de valor y cierre
08	Bibliografía y anexos

2 La solución

Tres modos de análisis sobre una misma plataforma

GeoAssets Intelligence es una aplicación web cuyo núcleo es un dashboard cartográfico. La plataforma orquesta tres tecnologías habilitadoras detrás de una experiencia única: el analista elige el modo de búsqueda y obtiene el mapa con activos puntuados.



2 La solución

Doce categorías de activo y un score auditable 0-100

Taxonomía jerárquica. Cinco super-categorías que se desglosan en doce sub-categorías específicas. Cada activo recibe un score de confianza auditable 0-100 mapeado al tier semántico LOW / MEDIUM / HIGH.

TAXONOMÍA • 5 SUPER → 12 SUB-CATEGORÍAS



PROCESO DE CLASIFICACIÓN • Cómo el LLM asigna cada activo



EJ. 01
Inditex Arteixo
→ **HQ** — Sede / HQ
Centro corporativo del grupo, oficina principal con todos los servicios.

EJ. 02
Tempe Inditex Elche
→ **FB** — Fábrica / Planta
Planta de producción de calzado, identificable por descripción manufactura.

EJ. 03
Plataforma Logística Zaragoza
→ **CL** — Centro logístico
Hub de distribución mayorista con tipo Google Places "warehouse".

SCORE 0-100 • TRES TIERS SEMÁNTICOS

HIGH 65 - 100
Evidencia suficiente y consistente. Aparece en el dashboard sin disclaimer.

MEDIUM 35 - 64
Evidencia parcial o conflictiva. Útil para análisis con revisión humana.

LOW 0 - 34
Evidencia escasa o contradictoria. Filtrado por defecto en el dashboard.

SUAVIZADO BETA
Cuando las señales son pocas o frágiles, el score crudo tiende a colapsar a extremos artificiales (0% o 100%). Aplicamos un suavizado conjugado con prior Beta(α , β) para regularizar hacia la media poblacional.

2

La solución

Visualización y exploración interactiva

Exploración guiada por color y filtro. El mapa codifica fuente y tipo del activo en el color del marker, el tier de confianza en su tamaño y opacidad. Una sidebar combinable filtra el universo, y cada marker abre un dialog con la descomposición auditable del score.

1 DOBLE PALETA DE COLOR EN EL MAPA

Toggle Fuente / Tipo en la esquina del mapa

MODO FUENTE (default)

● Maps API

● Documento

● Agente IA

↳ Si el activo viene de varias fuentes: agente > documento > maps

MODO TIPO (color por super-categoría)

● CORP

● OPS

● COM

● INFRA

● OTR

2 CODIFICACIÓN VISUAL DE CONFIANZA

Tamaño y opacidad por tier — el ojo distingue HIGH al instante

● HIGH

14 px · opacidad 1.0

● MEDIUM

10 px · opacidad 1.0

● LOW

10 px · opacidad 0.55 (semitransparente)

3 SIDEBAR DE FILTROS COMBINABLES

Toda combinación válida. Reduce el universo en tiempo real

● Búsqueda por nombre

Texto libre

● Dropdown super-categoría

5 opciones

● Dropdown sub-categoría

Se filtra automáticamente al elegir super

● Slider confianza mínima

0 → 100

● Chips de fuente

Maps · Document · Agent — con contadores

● Exportación

CSV / Excel

4 POPUP DE DETALLE · DESGLOSE DEL SCORE

Score final auditable — cada señal con peso y valor observado

Iberdrola, S.A. — Sede Central

Maps

HIGH 83

Ver en Google Maps ↗

Nombre incluye empresa

30%

100%

Tipo compatible

20%

100%

Ubicación corporativa

15%

50%

EL DIALOG MUESTRA

● Chip de fuente del análisis

● Chip de tier de confianza · score 0-100

● 6 señales (Maps) · 5 señales (Documento)

● Cada señal: peso explícito + valor observado

● Enlace directo a Google Maps

● Suavizado Beta para evitar extremos

MS

Management Solutions

Making things happen


© Management Solutions 2026. Todos los derechos reservados |

Página 12

2 La solución

Once señales auditables, ancladas en evidencia real

Score de confianza • 11 señales en 2 pipelines. Cada activo combina señales del pipeline correspondiente; el usuario puede abrir un dialog con la descomposición completa para auditoría reproducible.



2

La solución

Cuatro pasos del usuario hasta el resultado

Cuatro pasos del usuario hasta el resultado. el analista selecciona el modo, introduce el input, observa el streaming SSE en tiempo real y obtiene el dashboard cartográfico interactivo con los activos puntuados.



PASO 01
Selección de modo

La pantalla de arranque ofrece una sola search bar con tres affordances: el botón para adjuntar documento, el toggle de agente (icono robot) y el botón de envío.

ACCIONES

- Search bar central
- Toggle de agente IA
- Botón adjuntar archivo

INPUT
NINGUNO



PASO 02
Introducción del input

El modo se infiere del input — no hay un selector explícito de pipeline. La UI se adapta sin pasos intermedios para reducir fricción.

ACCIONES

- Texto libre → Pipeline Maps
- Toggle ON → Agente IA
- Documento → Pipeline Doc.

EVENTO SSE
job_started



PASO 03
Streaming SSE

Cada paso del pipeline actualiza el componente en tiempo real. El porcentaje global se calcula como progresión sobre los 5 nodos del flujo.

ACCIONES

- Empresa identificada
- Búsqueda completada
- Score calculado

EVENTO SSE
step_start / step_complete



PASO 04
Mapa interactivo

Al recibir complete, el frontend transiciona al dashboard cartográfico. Sidebar con activos ordenados, filtros y exportación CSV/Excel.

ACCIONES

- Mapa Leaflet con clusters
- Sidebar filtrable
- Export CSV/Excel

EVENTO SSE
complete

Índice


01	Contexto y oportunidad
02	La solución
03	Arquitectura técnica
04	Pipelines de análisis
05	Demostración y resultados
06	Benchmarking
07	Propuesta de valor y cierre
08	Bibliografía y anexos

3

Arquitectura técnica

Cinco capas, una decisión por capa

Stack tecnológico. Toda la plataforma se compone de tecnologías open source o gestionadas, con versiones fijadas en backend/pyproject.toml y frontend/package.json. Cada capa elige un componente por su criterio dominante.



3

Arquitectura técnica

Cuatro servicios, dos entidades, una orden de arranque

Despliegue + datos. docker-compose levanta cuatro servicios que se comunican con un único puerto público (3000); el backend (8000) y la base de datos (5432) y caché (6379) viven dentro de la red interna.

frontend:3000

PRESENTACIÓN

Vue 3 + Nginx alpine

- SPA reactiva con Composition API
- Mapa Leaflet con clustering
- Build estática servida por Nginx

backend:8000

API + ORQUESTACIÓN

FastAPI + Uvicorn

- Async nativo + OpenAPI auto
- Orchestrator de pipelines
- Stream SSE al cliente

postgres:5432

PERSISTENCIA

PostgreSQL 16-alpine

- Histórico durable de activos
- Índices espaciales
- Integridad referencial 1—N

redis:6379

CACHÉ

Redis 7-alpine

- TTL 86400s por empresa
- Clave company:{id}:assets
- Resp. JSON cacheada

companies · 8 columnas

PK	id	String	UUID
	name	String	identificador Nombre canónico
	cif	String?	CIF
	sector	String?	normalizado CNAE
	headquarters	String?	Coords HQ
	last_analyzed_at	DateTime?	identificada Última corrida
	total_assets	Integer	pipeline Conteo activos persistidos

assets · 25 columnas en 5 bloques funcionales

IDENTIFICACIÓN

id, company_id, name, raw_name, category, subcategory

GEOLOCALIZACIÓN

latitude, longitude, address, municipality, province, autonomous_community, postal_code

METADATOS FUNCIONALES

description, size_estimate, functional_tags, is_headquarters

FUENTE Y CONFIANZA

google_place_id, confidence_score, confidence_tier, data_sources

CONTACTO Y CONTROL

website, phone, created_at, updated_at

6
7
4
4
4

Relación 1—N. companies (1) —< assets (N) mediante assets.company_id (indexado, nullable=False). Las seis señales individuales del scoring no se persisten — solo el score agregado y el tier semántico.

3

Arquitectura técnica

Histórico durable, caché efímera, SSE sobre HTTP

Persistencia + protocolo de tiempo real. Todo lo escrito persiste en PostgreSQL; las consultas repetidas se sirven desde Redis con TTL de 24h. La comunicación backend → frontend usa Server-Sent Events sobre HTTP estándar — no WebSocket.

PostgreSQL 16-alpine · HISTÓRICO DURABLE

Histórico de activos y empresas con todos sus campos, accesible vía **GET /api/v1/companies/{id}/assets**. Integridad referencial e índices espaciales para consultas geográficas.

SE PERSISTE
score, tier

NO SE PERSISTE
6 señales raw

CONSULTA
integridad referencial

Redis 7-alpine · CACHÉ EFÍMERA TTL 24h

Caché por empresa: clave **company:{id}:assets**, valor JSON con la respuesta completa, TTL 86 400 segundos. Si el caché está caliente y el cliente no pide **force_refresh**, el orchestrator devuelve el cacheado.

TTL
24h

LATENCIA HIT
ms vs min

INVALIDACIÓN
force_refresh

✓ SSE SOBRE HTTP · ELEGIDO

✓ Comunicación unidireccional servidor → cliente sobre HTTP/1.1 estándar

✓ Reconexión automática del navegador, atraviesa proxies sin negociación

✓ API simple en cliente con EventSource — pocas líneas de código

✓ Suficiente para el flujo: cliente recibe eventos hasta complete

✗ WEBSOCKET · DESCARTADO

✗ Protocolo binario bidireccional — no necesario para nuestro flujo

✗ Requiere upgrade handshake y librería específica en cliente

✗ Reconexión manual y configuración adicional en proxies

✗ Innecesario cuando solo el servidor envía eventos al cliente

Decisión. SSE elimina toda la maquinaria de WebSocket para una semántica que no la necesita — el flujo es estrictamente del backend al cliente.

3

Arquitectura técnica

12-factor: configuración fuera del código

Tres principios. las ~36 variables de entorno del backend se agrupan por dominio en siete categorías. Los secrets nunca se commitan (viven en .env.secrets gitignored, separados de los defaults en .env.defaults), y cualquier umbral del sistema se cambia sin redeployment.

01



Cero credenciales en código

Una clase Settings carga os.environ al arrancar; los defaults viven en .env.defaults y los secretos en .env.secrets (gitignored).

02



Defaults vs secrets en ficheros separados

.env.defaults bajo control de versiones; .env.secrets ignorado y rellenado por entorno (dev, staging, producción).

03



Configuración sin redeploy

Umbrales, modelos LLM, concurrencias y TTL son variables — cambian en caliente sin tocar la imagen Docker.

VARIABLE	TIPO	DEFAULT	CATEGORÍA	USO
POSTGRES_HOST	str	localhost	DATOS	Conexión a PostgreSQL
POSTGRES_PASSWORD	secret	—	DATOS	Credencial sensible (gitignored)
REDIS_TTL_SECONDS	int	86400	CACHÉ	TTL de la caché por empresa
GOOGLE_MAPS_API_KEY	secret	—	APIS	Provider canónico de geolocalización
LITELLM_MODEL	str	azure/openai.gpt-oss-120b-1:0	LLM	Modelo LLM por defecto
Azure_REGION_NAME	str	eu-west-1	LLM	Región Azure
AGENT_MAX_DURATION_SECONDS	int	120	AGENTE	Timeout total del agente CrewAI
CONFIDENCE_THRESHOLD_HIGH	float	0.65	SCORING	Umbral configurable HIGH/MEDIUM

Tabla representativa de 8 variables. El backend gestiona ~36 variables agrupadas por dominio · selección reducida a las relevantes para esta sección.

Índice

01	Contexto y oportunidad
02	La solución
03	Arquitectura técnica
04	Pipelines de análisis
05	Demostración y resultados
06	Benchmarking
07	Propuesta de valor y cierre
08	Bibliografía y anexos

4 Pipelines de análisis

Tres pipelines, un mismo formato de salida

Visión general. Tres modos sobre la misma plataforma: cobertura amplia rápida con Maps, precisión documental con Documento, autonomía sobre la web con el Agente. Comparten formato de salida y modelo de scoring; sólo cambia la fuente.



MODO 01
Búsqueda Maps

El usuario teclea el nombre de la empresa. El sistema lanza el pipeline automático sobre Google Places API enriquecido con LLM y devuelve los activos clasificados sobre el mapa.

FLUJO

Searc
h

Classify

Enric
h

Scor
e

VENTAJAS

✓ Cero fricción para el analista

✓ Sin documento previo

✓ Cobertura amplia inmediata

COSTE/BENEFICIO

LATENCIA

~45 s

MEJOR CASO Empresas con alta presencia digital



MODO 02
Carga de documento

El usuario arrastra un PDF, DOCX o Excel con activos. El pipeline ejecuta extracción IA por chunks, deduplicación, geocoding y scoring documental sobre lo extraído.

FLUJO

Pars
e

Chun
k

Extrac
t

Dedu
p

Geocode

Scor
e

VENTAJAS

✓ Cobertura casi total

✓ Score documental alto

✓ Trazabilidad por mención

PRECISIÓN

LATENCIA

~60 s

MEJOR CASO Memoria anual o listado interno



MODO 03
Agente IA

El usuario activa el toggle de agente y teclea el nombre. Un agente CrewAI navega la web, descarga documentos candidatos, los valida y los procesa en el pipeline documento.

FLUJO

Searc
h

Fetc
h

Revie
w

Validate

Ru
n

VENTAJAS

✓ Recupera empresas opacas

✓ Validación humana en bucle

✓ Combina web + documento

AUTONOMÍA

LATENCIA

~3 min

MEJOR CASO Empresa sin presencia en Maps

4

Pipeline Maps · Pasos 1–2

Buscar mucho, filtrar bien

Search & classify. Generamos múltiples queries en paralelo contra Google Places y dejamos que el LLM separe el grano de la paja: descarta franquicias, competidores y POIs irrelevantes.

- 1 Search
- 2 Classify
- 3 Enrich
- 4 Score

1 PASO

search_maps

Múltiples queries con variantes del nombre. Combinamos sufijos ("Inditex sede", "Inditex fábrica", "Industria de Diseño Textil" ...) y los lanzamos en paralelo contra Google Places. Devuelve hasta N **place** con tipo, dirección y coordenadas.

FANOUT

► 8 queries → 64 places brutos ► paralelo asíncrono (httpx) ► dedupe por place_id de Google

DECISIÓN CLAVE

Sobre-buscar y filtrar después — más barato que buscar de menos y perder activos.

2 PASO

filter_and_classify

El LLM separa el grano de la paja. Descarta franquiciados, competidores, locales no productivos. Asigna a cada activo válido una de las 12 categorías del enum **AssetCategory** y su correspondiente supercategoría.

RECHAZADOS

42

VÁLIDOS

22

DECISIÓN CLAVE

Clasificar y filtrar en una sola llamada al LLM — evita un round-trip extra y mantiene contexto.

4 Pipeline Maps · Pasos 3–4

Enriquecer con detalles y puntuar con seis señales

Enrich & score. Un segundo round de Place Details añade web, teléfono y reviews; las reviews se analizan en busca de lenguaje B2B. Las seis señales se combinan con pesos fijos y suavizado Beta.



3 PASO

enrich_assets

Para cada activo válido se lanza una segunda llamada a **Places Details** que añade **website, teléfono y reviews** . Las reviews se analizan para detectar lenguaje B2B (frecuencia de "proveedor", "facturación", "logística").

SEÑALES NUEVAS POR ACTIVO

website_match → coincidencia de dominio con el oficial.

reviews_b2b → score 0–1 según vocabulario corporativo.

address_corporate → polígono industrial vs. zona residencial.

DECISIÓN CLAVE

Enriquecer sólo los válidos del paso 2 — el coste de Place Details es relevante en volumen.

4 PASO

score_assets · 6 señales

name_match		30%
Coincidencia léxica con el nombre del lugar Google Places		
type_match		20%
Compatibilidad del tipo Google Places con la categoría		
address_corporate		15%
Heurística baseline (valor neutro 0.5; pendiente de implementación específica)		
website_match		15%
Dominio web declarado coincide con dominio empresarial		
reviews_b2b		10%
Volumen de reseñas en Google Places (>100 → 0.8, >20 → 0.5, resto → 0.3)		
llm_confidence		10%
Confianza autorreportada por el LLM al clasificar		


Score final

$\sum w_i \cdot s_i \rightarrow \text{Beta}(\alpha=1+\text{raw}\cdot10, \beta=1+(1-\text{raw})\cdot10)$

4 Pipeline Documento · Pasos 1–3

Convertir un PDF de 80 páginas en activos estructurados

Parse → chunk → extract. Un PDF complejo de 80 páginas se transforma en 28 chunks Markdown semánticos; el LLM extrae menciones de activo en paralelo, cada una con la cita textual de la que vino.




4

Pipeline Documento · Pasos 4–6

Deduplicar, geocodificar, puntuar

Funnel del documento. 71 menciones brutas se reducen a 31 activos puntuados con tier. La deduplicación por similitud y el geocoding son los puntos donde más activos se pierden — pero pierden poco si el documento es bueno.



4 Pipeline Agente · Introducción

¿Y si la empresa no está en Maps ni hay documento?

Construimos un agente autónomo que **navega la web como lo haría un analista humano** : busca, evalúa, descarga y delega el procesamiento al pipeline de documentos. Mismo proceso, dos órdenes de magnitud menos tiempo.



H

ANALISTA HUMANO ·
Proceso clásico (~3 horas)

TAREAS ACTUALES

Buscar en Google con varias variantes del nombre.

Abrir las primeras 10 URLs y juzgar relevancia.

Descargar memorias, informes y landings de filiales.

Leer cada documento y extraer activos a mano.

TIEMPO MEDIO

~3 h

PROBLEMAS

No reproducible · sin scoring objetivo · escala mal en lotes de empresas.

A

AGENTE IA · T
Mismo proceso, ~3 minutos

STACK DEL AGENTE

CrewAI — orquesta los roles del agente y planifica acciones.

DuckDuckGo MCP — búsqueda web sin API key, vía Model Context Protocol.

OpenAI GPT-4o vía LiteLLM — razona sobre relevancia de cada URL candidata.

Document pipeline — reutilizado para el análisis final.

TIEMPO MEDIO

~3 min

DECISIÓN CLAVE

Reutilizar el pipeline de documentos en vez de duplicarlo — el agente sólo tiene que **encontrar** documentos válidos.

4

Pipeline Agente · Flujo de búsqueda

Eventos en tiempo real durante la navegación del agente

Streaming SSE. Cada decisión del agente se emite como evento: el frontend muestra la cadena de pensamiento, las URLs encontradas, los aceptados y los rechazados. Sin caja negra.

1 Search

2 Fetch

3 Review

4 Validate

5 Run

EVENTOS DEL AGENTE · VÍA SSE

1 thinking

Planifica próximas queries y razona sobre lo que ya ha encontrado.

1 searching

Lanza búsqueda web vía DuckDuckGo MCP.

1 found_urls

Devuelve URLs candidatas con título y snippet.

2 downloading

Descarga los documentos relevantes seleccionados.

3 accepted

Documento pasa los criterios y queda listo para revisión.

3 rejected

No relevante (artículo de prensa, blog, etc.) — se descarta.

3

✓

¿Qué cuenta como fuente válida?

Relevancia:

el documento menciona activos productivos de la empresa objetivo.

Formato estructurado:

PDFs corporativos, memorias, informes — no notas de prensa sueltas.

Frescura:

publicado en los últimos 3 años (configurable).

Idioma:

ES, EN o PT (configurable).

4

R

Human in the loop

Procesamiento paralelo con max concurrent configurable (default 3)

Resultados fusionables: si varios documentos cubren la misma empresa, se deduplican antes de mostrar.

Trazabilidad: cada activo final apunta al documento exacto del que se extrajo.

Auditoría: la decisión humana queda registrada en el job log.

DECISIÓN CLAVE

No procesar automáticamente — el coste por documento es alto y un falso positivo del agente contamina el resultado final.

4

REVISIÓN

2 documentos aceptados · 1 rechazados

5

CONFIRMAR Y PROCESAR →

✓

PDF

memoria-anual-2024.pdf

inditex.com · 240 p · ES · 2024

ACCEPTED

✓

PDF

plan-estrategico-2025.pdf

inditex.com · 52 p · ES · 2025

ACCEPTED

☐

HTML

expansion.com — inditex-resultados.html

prensa · sin estructura

REJECTED

Índice

01	Contexto y oportunidad
02	La solución
03	Arquitectura técnica
04	Pipelines de análisis
05	Demostración y resultados
06	Benchmarking
07	Propuesta de valor y cierre
08	Bibliografía y anexos

5

Demostración y resultados

Tres casos, una matriz común de evaluación

Marco de evaluación. Cada pipeline se evalúa con las mismas dimensiones —input, salida persistida, distribución de confianza y latencia observada— sobre corridas reales del sistema.

CASO			
Iberdrola	Maps	Repsol	Documento
Agente IA	Agente		
INPUT Nombre de empresa	PIPELINE Maps — Google Places + LLM	SALIDA OBSERVADA 76 activos • 70 HIGH	LATENCIA ~45 s
INPUT repsol_activos_productivos.docx	PIPELINE Documento — extracción + dedup + geocoding	SALIDA OBSERVADA 18 activos • 18 HIGH	LATENCIA ~60 s
INPUT Mercadona	PIPELINE Agente CrewAI + DuckDuckGo MCP	SALIDA OBSERVADA Documentos validados manualmente	LATENCIA ~2 min
Cobertura amplia y rápida.	Cobertura casi total con score documental alto.	Recupera empresas opacas para los otros pipelines.	

CRITERIOS DE EVALUACIÓN • Cuatro dimensiones comunes a todos los pipelines


INPUT Qué necesita el pipeline para arrancar	PIPELINE Tecnologías y pasos ejecutados	SALIDA Activos persistidos y distribución de tiers	LATENCIA Tiempo end-to-end por empresa
---	--	---	---

Alcance de la evaluación. Se reportan observaciones cualitativas sobre corridas reales. La validación de calidad se aporta como observación documentada por activo. No se incluye precision/recall numérico al no existir un ground truth público completo.

5 Demostración y resultados

Iberdrola — 76 activos persistidos, 70 en tier HIGH

Filtrado LLM aplicado. Sobre el corpus de Iberdrola — sede central en Hortaleza (Madrid), filiales productoras y red comercial Iberdrola Clientes — el sistema persiste 76 activos productivos en España y descarta candidatos brutos que no son patrimonio del grupo (oficinas comerciales sueltas, asesorías, etc.).



Spot-check cualitativo. Sede central en Hortaleza (Madrid), parques eólicos en Castilla y León, instalaciones fotovoltaicas en Andalucía, oficinas regionales y centros logísticos localizados correctamente. La masa de 76 activos refleja la verdadera escala del patrimonio productivo del grupo.


Caption del dashboard. Vista del dashboard con marker HQ (Iberdrola, S.A., Hortaleza) — categoría Sede Central · 82 %.

5 Demostración y resultados

Detalle de confianza · Trazabilidad por activo

Auditoría reproducible. Cualquier activo expone su descomposición de score en un dialog: la fuente del análisis, las señales utilizadas con sus pesos y valores, y la nota sobre el suavizado Beta. Dos analistas con el mismo input ven la misma evidencia.

1 POPUP DEL MARKER · DASHBOARD GeoAssets



1 · Click marker → popup con resumen del activo

Iberdrola, S.A. — sede central · C. de Tomás Redondo 1, Hortaleza (Madrid). Para auditar el detalle, abre el dialog de scoring →

2 DETALLE DE CONFIANZA · AUDITORÍA POR ACTIVO

Detalle de confianza

Score final

83%

Alta confianza

Fuente del análisis

Google Maps

Modelo IA

Señales utilizadas

Nombre incluye la empresa 30% 100%

Tipo compatible con activo productivo 20% 100%

Señal de ubicación corporativa 15% 50%

Dominio web corporativo 15% 90%

Perfil de reseñas B2B 10% 80%

Valoración del modelo IA 10% 100%

El score se suaviza con una distribución Beta para evitar valores extremos artificiales.

TIERS DE CONFIANZA

HIGH	≥ 80 %
MEDIUM	50 - 79 %
LOW	< 50 %

DISTRIBUCIÓN · 76 ACTIVOS

HIGH	70
MEDIUM	6
LOW	0

SUAVIZADO BETA

$$\Sigma (w_i \times v_i)$$

β → 83 %



2 · Detalle de confianza = dialog de auditoría

Trazabilidad por activo · 6 señales con pesos explícitos · Score final 83 % suavizado con distribución Beta · Misma evidencia para todos los analistas

Demostración y resultados

Repsol — 18 activos extraídos, todos en tier HIGH

Pipeline documento sobre un .docx corporativo: extracción IA por chunks, deduplicación, geocoding y scoring sin paso por Maps. Los markers se concentran en la península (refinerías, sede, terminales, laboratorio I+D) más La Pampilla en Perú.




Honestidad sobre alcance. El pipeline no filtra geográficamente — los activos del documento fuera de España (p. ej. Refinería La Pampilla, Perú) aparecen igualmente. Limitación reconocida y trabajada en futuras mejoras.

Caption del dashboard. Salida del pipeline documento sobre repsol_activos_productivos.docx.

5 Demostración y resultados

El agente razona, busca y filtra documentos públicos

El agente razona, busca y filtra documentos públicos. Eventos del agente expuestos en vivo en la vista de búsqueda — trazabilidad completa del razonamiento. Mercadona e Iberdrola usadas como inputs.



5

TIPOS DE EVENTOS SSE
Trazabilidad completa del razonamiento

EVENTOS EN VIVO • SSE FEED

- thinking** Planifica los próximos pasos sobre la empresa
- searching** Lanza búsqueda web con DuckDuckGo MCP
- found_urls** Reporta URLs candidatas y argumenta relevancia
- downloading** Descarga documentos validados
- accepted** El humano confirma o rechaza antes de procesar

~2 min

LATENCIA OBSERVADA
Búsqueda + descarga + validación humana

Validación humana en bucle. Tras la búsqueda, AgentDocumentReviewView presenta al usuario los ficheros aceptados con sus metadatos extraídos. El analista valida o descarta cada uno antes de pasar al pipeline documento.
Caption del dashboard. Vista AgentSearchView durante una corrida real (Iberdrola): el agente delibera, busca y reporta hallazgos.

5

Demostración y resultados

De 2-4 horas manuales a aproximadamente 2 minutos automatizados

Síntesis de la sección. la ejecución automatizada de GeoAssets sobre una misma empresa reduce el tiempo del analista en un factor 60-120x manteniendo trazabilidad por fuente, score auditable y reproducibilidad — ganancias que el flujo manual no puede ofrecer.

AS-IS • FLUJO MANUAL

2-4 h por empresa

- Búsqueda manual en Maps, web corporativa y memoria anual.
- Dependiente del criterio del analista — no replicable.
- Sin trazabilidad de fuentes ni score por activo.

TO-BE • GEOASSETS INTELLIGENCE

~2 min por empresa

- Tres pipelines según el input disponible (nombre · documento · agente).
- Trazabilidad por fuente: Maps API, Document o Agente.
- Score Beta-smoothed auditable por activo y por señal.

×60-120

Reducción de tiempo por empresa según el caso. Banda explícita: extremo inferior con flujo manual rápido (cobertura parcial), extremo superior con análisis exhaustivo y reproducible.

DEMOSTRADO

- ✓ Tres pipelines funcionan extremo a extremo sobre empresas reales.
- ✓ Tiempos del orden de minutos, frente a horas en el flujo manual.
- ✓ Trazabilidad por activo: fuente, señales y score auditable.

NO AFIRMADO • PENDIENTE

- ✗ Precision/recall numérico — sin ground truth de validación.
- ✗ Filtrado geográfico por país en pipeline documento.
- ✗ Cobertura del agente sobre empresas opacas — no probado.

Índice

01	Contexto y oportunidad
02	La solución
03	Arquitectura técnica
04	Pipelines de análisis
05	Demostración y resultados
06	Benchmarking
07	Propuesta de valor y cierre
08	Bibliografía y anexos

6

Benchmarking

El mapa que nadie tiene

¿Dónde están los activos de Repsol en España? Nadie lo sabe con certeza.

Paso del analista	Fuente	Tiempo
Buscar web corporativa	Manual	2-4 h
Leer informe anual (PDF ~200 págs.)	Manual	4-8 h
Cruzar con Google Maps	Manual	3-6 h
Geocodificar y validar cada activo	Manual	4-8 h
Documentar con confianza mínima	Manual	2-4 h
TOTAL por empresa	—	15-30 h

15 – 30 h
/ empresa

de trabajo manual para localizar y validar activos productivos.

ESCALA

3,2 M empresas registradas en España

COSTE

Un analista de due diligence dedica el 34 % de su tiempo a localizar activos (Deloitte M&A 2024).

RIESGO

78 % de errores de valoración en deals industriales viene de activos no inventariados (KPMG 2023).

REGULACIÓN

CSRD (2025): empresas >250 empleados deben reportar riesgo físico por activo. Casi nadie tiene el inventario.

6

Benchmarking

Cuatro familias, cuatro brechas

Miles de millones invertidos en este espacio. Solo GeoAsset resuelve el caso de uso de geolocalización de activos productivos

1 • Inteligencia satelital

Monitorizan activos visibles desde el cielo (tanques, naves, oleoductos). No descubren activos desconocidos ni procesan documentos.

Empresa	Financiación	Foco
Kayrros	\$78M · adquirida 2026	Solo energía
Orbital Insight	\$111M · adq. Privateer	Commodities, retail
AiDash	\$58,5M	Utilities, infraestructura
LiveEO	€28M	Infraestructura lineal

BRECHA · Imágenes premium (\$50K–\$500K/año). Solo activos grandes y visibles. No leen documentos. Sin confianza probabilística por activo.

2 • Agregadores de datos financieros

Saben todo de la empresa como entidad legal. No saben nada de sus instalaciones físicas.

Empresa	Revenue '24	Activos físicos
S&P Global MI	\$4,92B	No · solo financiero
MSCI ESG	Parte de \$2,8B	Parcial · >\$200K/año
Dun & Bradstreet	\$2,38B	Registros, no activos
Bureau van Dijk	N/D	Sólo sede registrada

BRECHA · Saben quién es la empresa, no dónde están sus fábricas. MSCI valida el espacio pero es enterprise-only y no cubre España de forma nativa.

3 • Plataformas ESG

Calculan riesgo sobre activos que el cliente ya les da. La capa de descubrimiento no existe en su producto.

Empresa	Financiación	Limitación
Clarity AI	\$240M · >\$1B val.	No localiza activos
Sustainalytics	Adq. Morningstar \$1,75B	Sin geo de planta
Trucost (S&P)	Parte de S&P	Huella estimada
Cervest	\$50M	Pide coordenadas

BRECHA · Todas piden al cliente que aporte el inventario. GeoAssets resuelve la capa cero que estas plataformas dan por resuelta.

4 • Startups AI-nativas emergentes

Aplican IA geoespacial a un único vertical. Ninguno cruza sectores ni usa documentos corporativos.

Empresa	Financiación	Foco
Plume (YC W25)	Pre-seed €3,3M	Site selection EERR
Blackshark.ai	\$17M	Gemelos digitales
Orbital Sidekick	\$55M	Oleoductos
SpaceKnow	\$12M	Actividad industrial

BRECHA · Verticales puros (energía, ciudad, petróleo). Ninguno aborda descubrimiento multi-sector vía documentos + web + Maps API con ESG integrado.

Índice

01	Contexto y oportunidad
02	La solución
03	Arquitectura técnica
04	Pipelines de análisis
05	Demostración y resultados
06	Benchmarking
07	Propuesta de valor y cierre
08	Bibliografía y anexos

7

De 4 horas a 2 minutos. Con mejor cobertura y trazabilidad.

PROPUESTA DE VALOR · TO BE

AS IS · HOY

Proceso manual del analista

Tiempo / empresa	2-4 horas
Cobertura	40-60 %
Reproducibilidad	No
Score objetivo	No



TO BE · GEOASSETS

Pipeline automatizado

Tiempo / empresa	~2 min
Cobertura	≥ 80 %
Reproducibilidad	Sí (caché 24h)
Score objetivo	0-100 + señales

PARA ANALISTAS

Tiempo

De 4 horas a ~2 minutos por empresa con mayor cobertura.

PARA RIESGO / M&A

Score reproducible

Due diligence con criterios objetivos y trazables.

PARA ESG

Exposición ambiental

Geolocalización de activos industriales para análisis de riesgo climático.

Índice

01	Contexto y oportunidad
02	La solución
03	Arquitectura técnica
04	Pipelines de análisis
05	Demostración y resultados
06	Benchmarking
07	Propuesta de valor y cierre
08	Bibliografía y anexos

El patrimonio productivo de una empresa es visible. Sólo hay que saber dónde mirar.

CONCLUSIONES

- ✓ **Hipótesis validada** — LLMs + APIs geoespaciales + agentes automatizan el análisis con alta precisión.
- ✓ **Aporte técnico** — sistema modular de pipelines con scoring unificado y UI auditable.
- ✓ **Aporte académico** — framework reproducible aplicable a otros dominios de inteligencia geoespacial.

LIMITACIONES & MITIGACIÓN

Dependencia Maps en zonas rurales → **complementar con Agente**. LLM no determinista → **validación por tier**. Cobertura España → **expansión EMEA**.

LÍNEAS FUTURAS

L1 · 2026 H2
Expansión geográfica
Portugal, LatAm


L2 · 2027
Fine-tuning del clasificador
Datos validados internamente

L3 · 2027
API pública con auth
Integración B2B

L4 · 2028
Detección de cambios
Alertas activos cerrados

BIBLIOGRAFÍA CLAVE

- Brown et al. (2020). *Language Models are Few-Shot Learners*. NeurIPS.
- Google. *Places API Documentation*. developers.google.com/maps.
- LiteLLM*. litellm.vercel.app — proxy LLM multi-proveedor.
- CrewAI Framework*. crewai.com.
- Beta distribution priors aplicados a sistemas de scoring.
- FastAPI · *Server-Sent Events patterns*.



REPOSITORIO · DEMO
github.com/[autor]
/geoassets-intelligence